



# Regresie logistică (Logistic Regression)




Ce ne așteaptă?

1. Funcția sigmoid
2. Aparatul matematic
3. Instrumente Scikit-Learn pentru regresia logistică

# 1. Funcția sigmoid

## ■ Funcția sigmoid


$$\sigma(x) = \frac{1}{1 + e^{-x}}$$



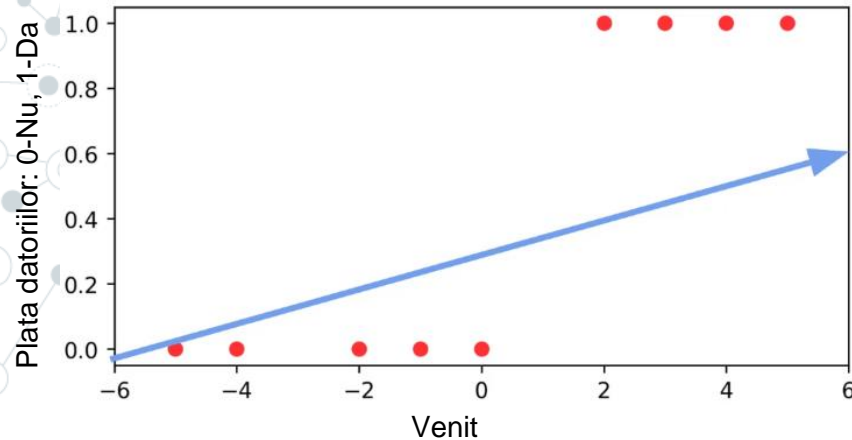
## ■ Datele istorice

Venit	-5	-4	-2	-1	0	2	3	4	5
Plata datoriilor	0	0	0	0	0	1	1	1	1

## ■ Graficul datelor istorice

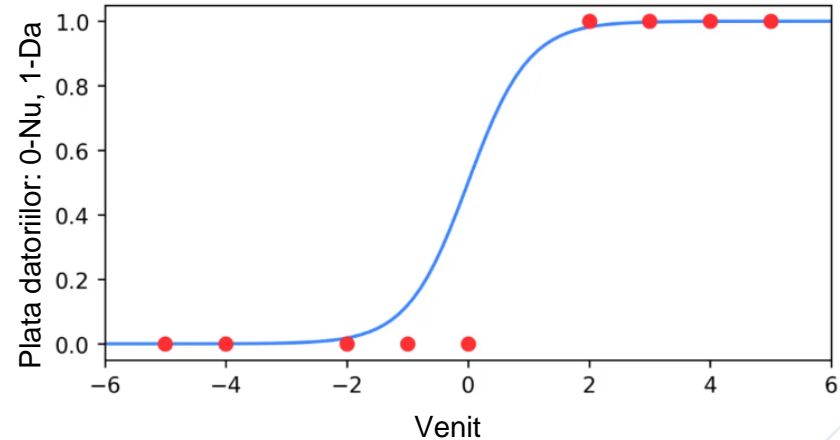


## Regresia liniară simplă



$$\text{Plata datorii} = \beta_0 + \beta_1 * \text{Venit}$$

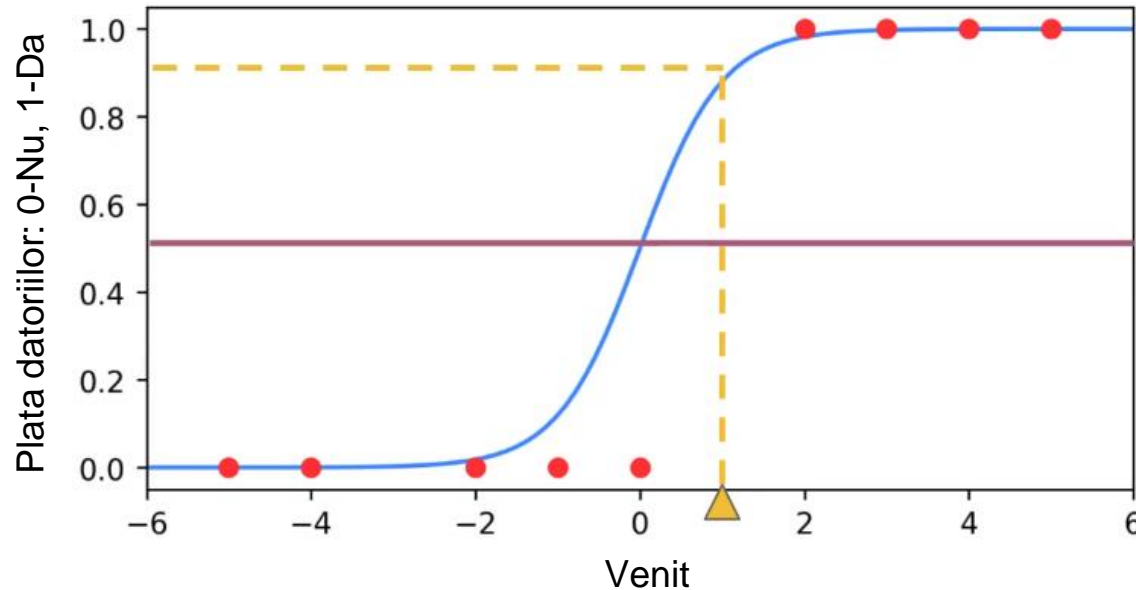
## Regresie logică simplă



$$p(\text{Plata datorii}) = \frac{1}{1 + e^{-\text{Venit}}}$$

$p()$  – probabilitatea

- Care este probabilitatea că va plăti datoriile dacă venitul este 1?




0.5 – nivel de decizie

$$p(\text{Plata datorii})_{\text{venit}=1} = 0,9 \rightarrow 1$$


## 2. Aparatul matematic

### ■ Regresia liniară simplă



$$\hat{y} = \beta_0 + \beta_1 x$$

### ■ Regresie logistică simplă



$$\hat{y} = \sigma(\beta_0 + \beta_1 x) = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}}$$


- Cota unui eveniment e dacă se știe probabilitatea acestuia  $p(e)$

$$cota(e) = \frac{p(e)}{1 - p(e)}$$

- Dependența lui  $\hat{y}$  de coeficienți  $\beta_i$

$$\hat{y} = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x)}} \rightarrow \hat{y} + \hat{y} * e^{-(\beta_0 + \beta_1 x)} = 1 \rightarrow \hat{y} * e^{-(\beta_0 + \beta_1 x)} = 1 - \hat{y} \rightarrow \frac{\hat{y}}{1 - \hat{y}} = e^{(\beta_0 + \beta_1 x)}$$

$$\ln\left(\frac{\hat{y}}{1 - \hat{y}}\right) = \beta_0 + \beta_1 x$$







## Conversia logaritmului cotei în probabilitate

$$\ln\left(\frac{p}{1-p}\right) = \ln(cota) \rightarrow \frac{p}{1-p} = e^{\ln(cota)} \rightarrow p = (1-p)e^{\ln(cota)} \rightarrow p = e^{\ln(cota)} - p * e^{\ln(cota)} \rightarrow$$


$$\rightarrow p + p * e^{\ln(cota)} = e^{\ln(cota)} \rightarrow p = \frac{e^{\ln(cota)}}{1 + e^{\ln(cota)}}$$



$$p = \frac{e^{\ln(cota)}}{1 + e^{\ln(cota)}}$$




## Dependență probabilităților de valorile coeficienților $\beta_i$



## Cei mai buni coeficienți $\beta_i$ vor corespunde valorii maxime a probabilității $p$ calculată ca produsul probabilităților conform exemplului

$$p = 0,9 * 0,8 * 0,65 * 0,55 * (1 - 0,3) * (1 - 0,2) * (1 - 0,08) * (1 - 0,02) = 0,129$$



### 3. Instrumente Scikit-Learn pentru regresia logică

- Se importa clasa algoritmului LogisticRegression

```
from sklearn.linear_model import LogisticRegression
```

- Se creează un model cu fixarea valorilor hiper-parametrilor:

- **penalty** – tipul penalității la regularizare (valori posibile = {'l1', 'l2', 'elasticnet', 'none'}, implicit='l2')
- **C** - coeficientul invers de includere a penalizării (valori posibile = float, implicit=1.0)
- **solver** – algoritmul utilizat pentru minimizarea sumei erorilor la realizarea trainingului (valori posibile = {'newton-cg', 'lbfgs', 'liblinear', 'sag', 'saga'}, implicit='lbfgs')
- **multi\_class** – specifica dacă sunt 2 clase sau mai multe (valori posibile = {'auto', 'ovr' (pentru binar), 'multinomial' (pentru multi-class)}, implicit='auto')
- **Max\_iter** - numărul maxim de iterații pentru minimizarea sumei erorilor (valori posibile = int, implicit=100)
- **L1\_ratio** – (doar dacă penalty='elasticnet') gradul de includere a regularizării l1

```
model = LogisticRegression(solver='saga', multi_class='multinomial',  
penalty='l1', C=120, max_iter=100000)
```

- Se realizează trainingul modelului pe datele de training  
`model.fit(X_train, y_train)`
- Se vizualizează coeficienții modelului  
`model.coef_`
- Se realizează predicția pe datele de test  
`y_pred = model.predict(X_test)`
- Se realizează predicția pe datele de test cu afișarea probabilităților  
`y_pred = model.predict_proba(X_test)`

- Se evaluează performanțele modelului

- Se determina acuratețea modelului

```
from sklearn.metrics import accuracy_score  
accuracy_score(y_test, y_pred)
```

- Se vizualizează matricea confuziilor

```
from sklearn.metrics import confusion_matrix  
cm=confusion_matrix(y_test, y_pred)  
cm
```

- Se vizualizează grafic matricea confuziilor

```
from sklearn.metrics import ConfusionMatrixDisplay  
ConfusionMatrixDisplay(cm, display_labels=model.classes_).plot();
```

- Se afișează raportul de clasificare - classification\_report

```
from sklearn.metrics import classification_report  
print(classification_report(y_test, y_pred))
```