Random Forest

Ce ne așteaptă?

1. Esența algoritmului Random Forest
2. Numărul arborilor și al caracteristicilor
3. Bootstrapping
4. Eroarea Out-of-Bag
5. Instrumente Scikit-Learn

1. Esența algoritmului Random Forest

- **Neajunsurile algoritmului Decision Trees**
  - **Lipsa garanției utilizării tuturor caracteristicilor**

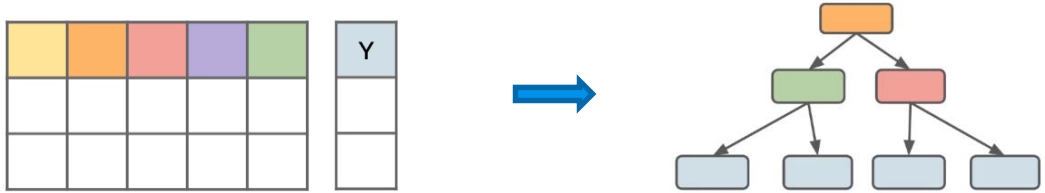

  - **Influența exagerată a caracteristicii de bază asupra structurii arborelui**

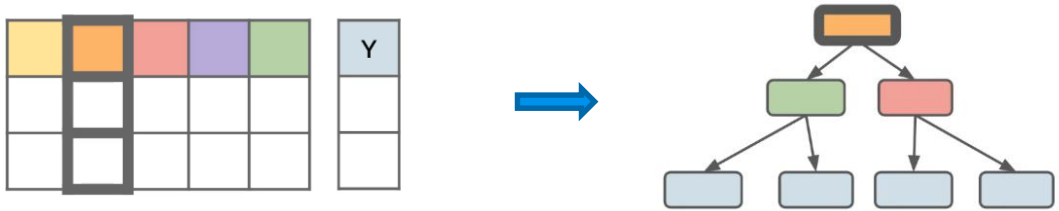

  - **Probabilitate înaltă de apariție a efectului overfitting**

- **Random Forest utilizează doar un subset aliator format din câteva caracteristici pentru fiecare procedură de divizare**

Prima etapă de divizare

A doua etapă de divizare

A doua etapă de divizare

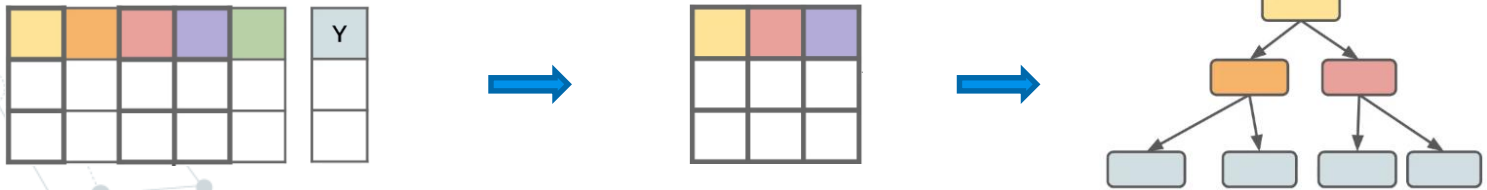

- **Random Forest permite crearea mai multor arbori după acest principiu**

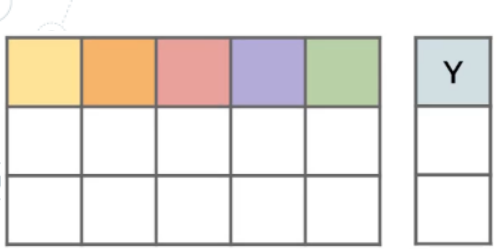

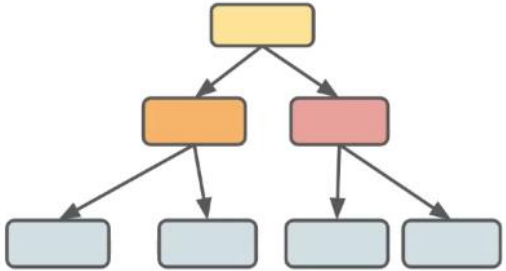

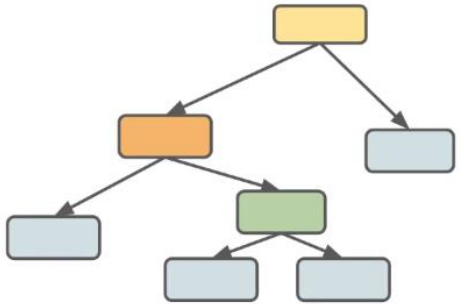

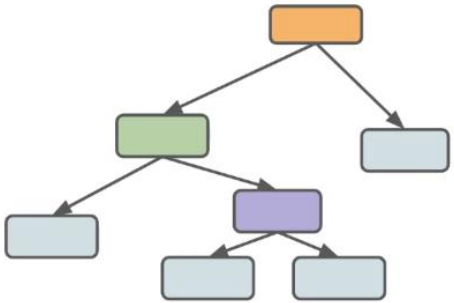

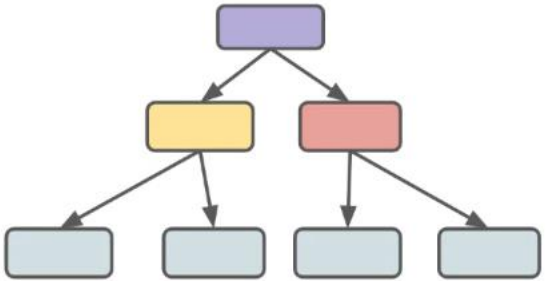

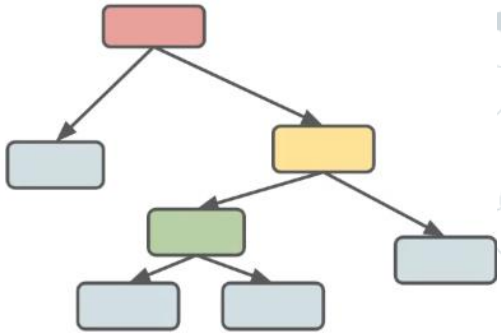

- **Realizarea predicției în Random Forest în cazul sarcinilor de clasificare**

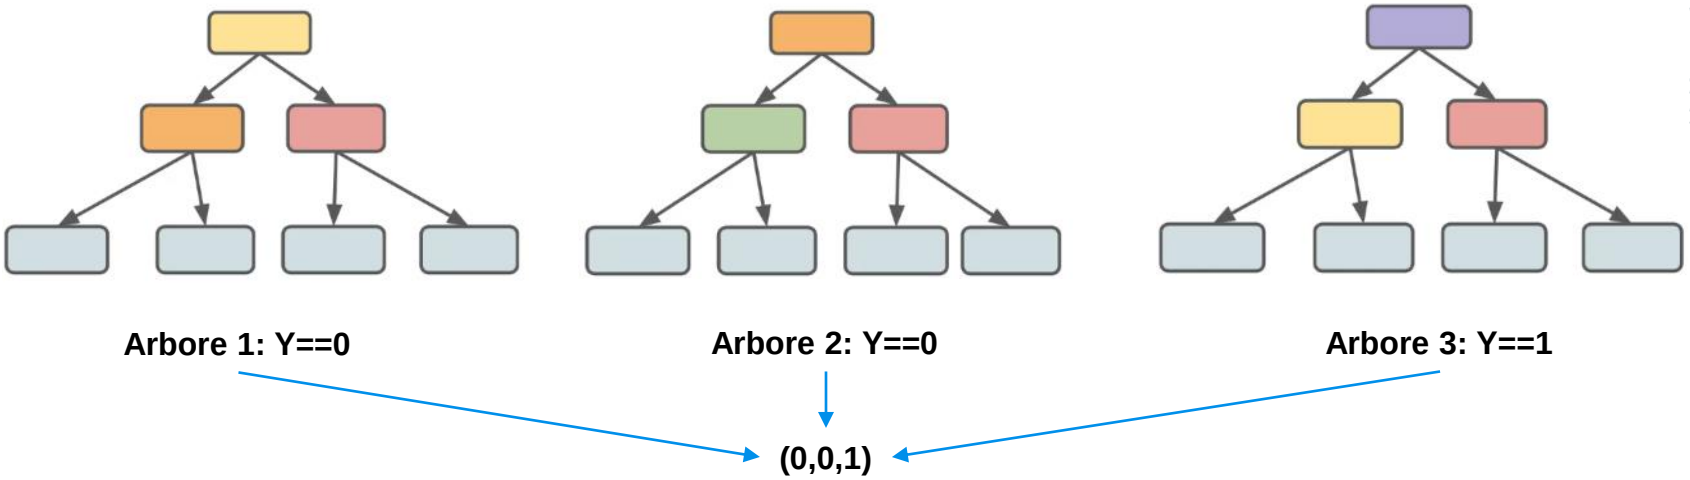

- **În cazul sarcinilor de clasificare valoarea predicție se va considera valoarea majoritară în rezultatele tuturor arborilor Y==0**

- **Realizarea predicției în Random Forest în cazul sarcinilor de regresie**

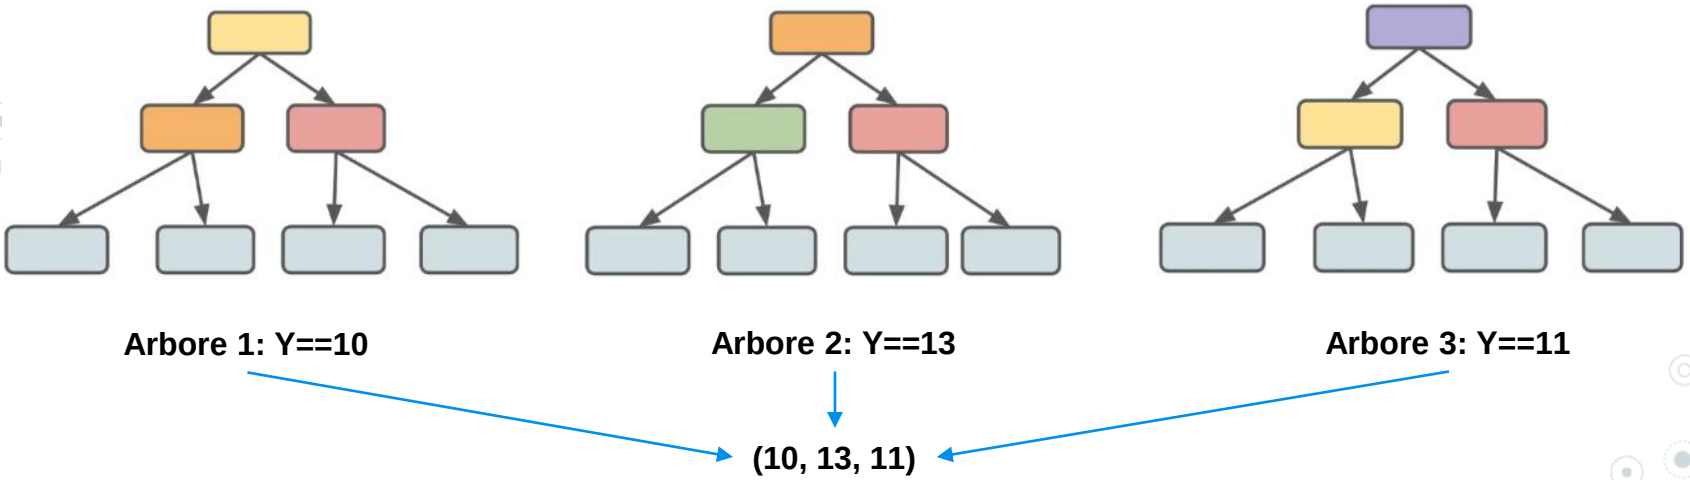

- **În cazul sarcinilor de regresie valoarea predicție se va considera valoarea medie a rezultatelor tuturor arborilor Y==11,3**

2. Numărul arborilor și al caracteristicilor

- Numărul arborilor ce vor fi considerați în algoritmul Random Forest poate fi nelimitat fără a crea apariția efectului overfitting
- Însă de la un număr oarecare se va constata:
  - Noii arbori nu mai conțin informație noua deoarece aceștia sunt corelați cu cei existenți
  - Noii arbori reprezintă copii ai arborilor existenți
- Numărul optim al arborilor variază între 64-128 în funcție de numarul de caracteristici
- Pentru selectarea numărului optim de arbori se va utiliza unul din mecanismele:
  - Cross Validation
  - Metoda ‘cotului’ (dependența erorii de numărul arborilor)

- Numărul caracteristicilor va determina câte caracteristici ale setului se vor include în subsetul selectat aliator
- Pentru sarcini de clasificare numărul optim de caracteristici determinat empiric se consideră $\sqrt{N}$, unde N numărul total
- Pentru sarcini de regresie numărul optim de caracteristici determinat empiric se consideră $\frac{N}{3}$, unde N numărul total
- Un alt număr optim al caracteristicilor ar putea fi $log_2(N+1)$, unde N numărul total

3. Bootstrapping

- Bootstrapping este procedura de selectarea aleatoare în procesul de divizare nu doar a caracteristicilor dar și a datelor
- Bootstrapping presupune că unele date pot să nu participe în procesul de divizare, iar unele pot participa de mai multe ori
- Bootstrapping exclude efectul formării arborilor corelați sau a arborilor copii

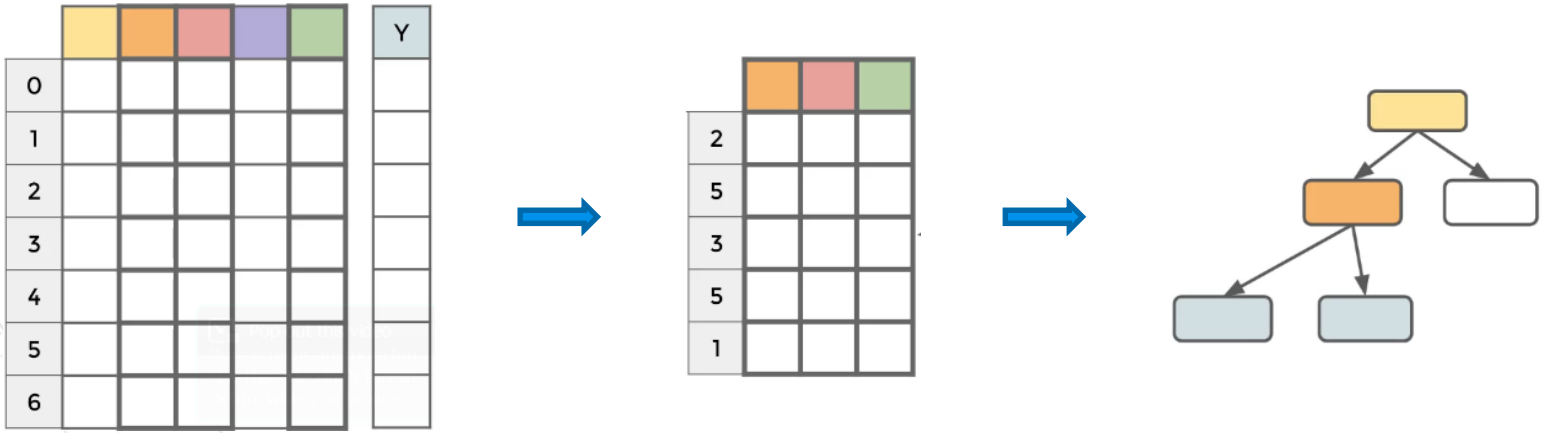

4. Eroarea Out-of-Bag

- Eroarea Out-of-Bag (OOB) este un parametru suplimentar de apreciere a performanțelor modelului ce include bootstrapping
- Eroarea Out-of-Bag (OOB) se obține prin comparația valorilor reale cu valorile predicție pe datele ce au fost excluse prin procedura de bootstrapping

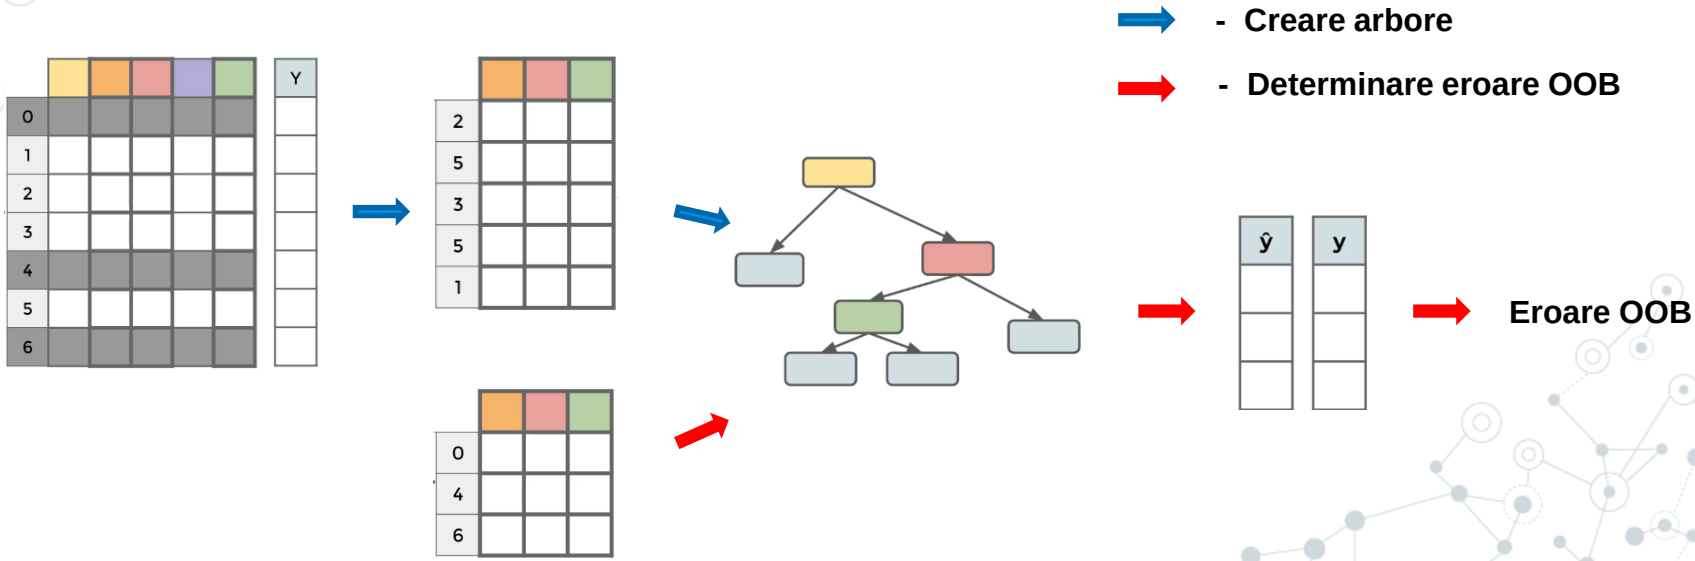

5. Instrumente Scikit-Learn

- **Random Forest pentru sarcini de clasificare**
  - **Se importa clasa algoritmului DecisionTreeClassifier**

```
from sklearn.tree import DecisionTreeClassifier
```

  - **Se creează un model cu fixarea valorilor hiper-parametrilor:**
    - **criterion, max_depth, max_leaf_node, min_impurity_decrease – identic algoritmului Decision Trees**
    - **n_estimators - numărul de arbori ai algoritmului (valori posibile = int, implicit =100)**
    - **max_fearures - numărul maxim al caracteristicilor unui subset (valori posibile =int, {"auto", "sqrt", "log2"}, implicit="auto")**
    - **bootstrap – includerea procedurii bootstrapping (valori posibile = bool, implicit=True)**
    - **oob_score – includerea determinarii erorii OOB (valori posibile = bool, implicit=False)**

```
model = DecisionTreeClassifier(n_estimators =100, max_fearures
="sqrt", bootstrap=True, oob_score = True)
```

- Se realizează trainingul modelului pe datele de training

```
model.fit(X_train, y_train)
```

- Se vizualizează importanța fiecărei caracteristici

```
model.feature_importances_
```

- Se realizează predicția pe datele de test

```
y_pred = model.predict(X_test)
```

- Se realizează predicția pe datele de test cu afișarea probabilităților

```
y_pred = model.predict_proba(X_test)
```

- Se se vizualizeză eroarea OOB

```
model.oob_score_
```

- **Random Forest pentru sarcini de regresie**
  - **Se importa clasa algoritmului RandomForestRegressor**

```
from sklearn.tree import RandomForestRegressor
```

  - **Se creează modelul :**

```
model = RandomForestRegressor()
```

  - **Se realizează trainingul modelului pe datele de training**

```
model.fit(X_train, y_train)
```

  - **Se realizează predicția pe datele de test**

```
y_pred = model.predict(X_test)
```